

SemanticPromptTransfer v0.21 운영 요구사항

- 기준 버전: semantic-prompt-transfer==0.21.0
- 기준일: 2026-08-31
- 기본 표현: L0
- 적용 범위: 승인된 최소 HTML 인터페이스, 문서 생명주기, 다중 문서 RAG, CPU 초안 생성, Word 다운로드

1. 목적

v0.21은 v0.20의 검색·근거 우선순위·FEW SHOT 격리 계약을 유지하면서 브라우저 화면과 운영 코드를 연결한다. 사용자는 한 건의 신용조사서와 여러 기타 첨부자료를 업로드하고, 각 파일의 처리률을 확인하며, 파일 삭제와 심사의견 Word 다운로드를 수행한다.

2. 고정 인터페이스

메인 화면은 다음 네 기능만 제공한다.

1. 신용조사서 1개 업로드 및 진행률
2. 기타 첨부자료 복수 업로드 및 진행률
3. 업로드 자료현황 조회
4. 심사의견 Word 다운로드 및 진행률

자료현황의 각 행은 파일명, 자료유형, 파일크기, 진행단계, 삭제 버튼을 가진다. 삭제 버튼은 서버가 원본 파일과 해당 문서의 임베딩 벡터 삭제를 모두 확인한 뒤에만 행을 제거한다.

3. 범위 키와 단일 벡터 DB

모든 청크와 파일은 다음 복합 범위를 가진다.

$S_d = (\text{tenant_id}, \text{case_id}, \text{document_id})$

여러 PDF는 하나의 벡터 DB 컬렉션에 적재하되 검색은 최소한 tenant_id와 case_id로 제한한다. 문서 교체와 삭제는 document_id까지 포함한 범위로 수행한다.

전역 청크 ID는 다음 결정적 함수로 생성한다.

$g = H(\text{tenant_id} \parallel \text{case_id} \parallel \text{document_id} \parallel \text{local_chunk_id} \parallel \text{level})$

4. 파일 처리 상태

상태	화면 단계	기본 진행률
UPLOADED	파일적재	15
VALIDATING	파일검증	25
PARSING	파일해석	45
INDEXING	벡터임베딩	70
READY	완료	100
FAILED	실패	0
DELETING	삭제중	기존 값 유지
DELETED	삭제완료	100

실제 처리기는 더 세밀한 진행률을 전달할 수 있다. 정상 처리 중 진행률은 감소할 수 없다.

5. 신용조사서와 첨부자료

신용조사서는 한 심사건에 활성 파일 1개만 허용한다. 규격화된 Excel 매핑으로 셀 단위 기초자료를 읽고 항목별 자료와 공통 자료로 분리한다. 기타 첨부자료는 복수 파일을 허용하고 L0 청크로 변환해 단일 벡터 DB에 적재한다.

근거 우선순위는 고정한다.

TIER_1 > TIER_2 > TIER_3

- TIER_1: 신용조사서 내 해당 심사항목 기초자료
- TIER_2: 신용조사서 공통 기초자료
- TIER_3: 기타 첨부자료 검색 근거

FEW SHOT은 여신유형·산업분류·상황 태그로 선택하지만 사실 근거가 아니다.

6. 삭제 원자성 경계

서로 다른 저장소를 하나의 DB 트랜잭션으로 묶을 수 없으므로, v0.21은 검증 가능한 단계적 삭제를 사용한다.

1. 레지스트리 상태를 DELETING으로 전환해 신규 사용을 차단한다.
2. tenant_id + case_id + document_id에 해당하는 모든 벡터를 삭제한다.
3. 같은 필터의 벡터 수가 0인지 확인한다.

4. 파생 산출물과 서버 원본 파일을 삭제한다.
5. 원본 파일이 존재하지 않는지 확인한다.
6. 레지스트리를 DELETED로 전환한다.

중간 실패 시 FAILED로 남기고 화면에서 성공으로 제거하지 않는다. 감사 이벤트는 보존한다. 사용자의 PC에 있는 업로드 전 원본은 삭제 대상이 아니다.

7. HTML 대응 애플리케이션 계약

OperationalApplicationService는 다음 작업을 제공한다.

- 업로드 등록
- 파일 처리 상태 갱신
- 신용조사서/기타 첨부자료 그룹 조회
- 문서 범위 삭제
- 심사의견 작업 상태 조회

선택형 FastAPI 어댑터는 업로드, 파일목록, 삭제, 심사의견 시작, 진행조회, Word 다운로드 경로를 제공한다. 실제 PDF/Excel 전처리와 인덱싱은 UploadProcessor 어댑터로 주입한다.

8. CPU LLM 모듈

초기 생성기는 TextGenerator 프로토콜 뒤에 위치한다.

ReviewGenerationOrchestrator

- > TextGenerator
- > TransformersCpuGenerator
- > EvidenceTemplateGenerator (fallback)

기본 소형 모델 후보는 Qwen/Qwen2.5-0.5B-Instruct이다. 모델은 wheel에 포함하지 않으며 프로세스 시작 시 1회 로드해 CPU에서 재사용한다. 생성은 탐욕적 디코딩, 짧은 출력 한도, 캐시 사용을 기본으로 한다.

기본 생성이 실패하거나 다음 조건을 위반하면 근거형 폴백을 사용한다.

- 현재 심사건 evidence_id가 없음
- 현재 근거에 없는 수치가 포함됨
- 빈 출력

폴백은 LLM을 대체하는 최종 품질 구현이 아니라 초기 운영 연결과 실패 복구용이다. 향후 내부 LLM 또는 API LLM은 generate(messages) -> str 계약만 구현하면 교체할 수 있다.

9. 고정 심사항목과 생성 흐름

1. 재무제표 주요계정
2. 수익성
3. 재무안정성 및 자산의 질
4. 현금흐름 및 채무상환능력
5. 주요 매출처 및 매출비중 변동 추이

진행 흐름은 입력검사, 신용조사서 로드, 첨부자료 검색, 5개 항목 생성·검증, 전체 검증, DOCX 생성, 완료 순서다. 다운로드 버튼은 작업 진행률이 100이고 Word 파일이 존재할 때만 활성화한다.

10. 검증 기준

- 기존 L0 청크 회귀 동일성
- 다중 문서 단일 인덱스 UPSERT
- tenant/case 검색 격리
- 파일별 진행률과 화면 단계
- 삭제 후 벡터 수 0
- 삭제 후 서버 원본 부재
- 삭제 실패 시 원본 보존 및 FAILED
- CPU 어댑터 교체 가능성
- 근거형 폴백의 수차·인용 검증 통과
- 다섯 심사항목 Word 생성과 진행률 100
- wheel/sdist 설치 및 패키지 내 HTML 포함

11. 운영 배포 전 잔여 과제

- 실제 은행 신용조사서 매핑 확정
- PDF 전처리기와 UploadProcessor 연결
- 인증·권한·악성파일 검사
- 객체 저장소와 운영 Vector DB 어댑터
- 비동기 작업 큐와 다중 서버 진행률 저장
- 실제 CPU 모델 파일 배포 및 성능 측정
- 내부 LLM 교체와 품질 평가
- 공식 Word 양식과 은행별 교차항목 검증